

Inferência Estatística

Visão geral e ilustração computacional

Prof. Me. Lineu Alberto Cavazani de Freitas

Departamento de Estatística
Laboratório de Estatística e Geoinformação





Introdução

Introdução

Já discutimos os conceitos de **população**, **amostra** e **inferência**.

- ▶ **População:** conjunto de todos os elementos que compartilham alguma característica comum que temos interesse em estudar.
- ▶ **Amostra:** subconjunto da população.
- ▶ **Inferência:** ramo da Estatística que tem como objetivo estudar a **população** por meio de evidências fornecidas por uma **amostra**.

Introdução

- ▶ Muitas vezes estamos interessados em **quantidades populacionais**, contudo trabalhar com a população pode ser custoso ou até mesmo impossível.
- ▶ A solução é trabalhar com um subconjunto da população, isto é, uma **amostra**.
- ▶ As técnicas de **amostragem** geram subconjuntos **representativos** da população para estimar quantidades de interesse (uma média, uma variância, uma proporção, etc).




Figura 1. Processo de inferência estatística.

Introdução

- ▶ Contudo é intuitivo notar que, caso se repita o processo de amostragem, uma amostra diferente da inicial será obtida.
- ▶ Consequentemente, as medidas de interesse calculadas (média, variância, etc.) em diferentes amostras não serão iguais.
- ▶ Isto quer dizer que mesmo o procedimento de amostragem estando correto sempre haverá aleatoriedade envolvida e os valores calculados com base na amostra são **candidatos** à quantidade na população.

Introdução

- ▶ Devido à **natureza aleatória**, todas as quantidades associadas à amostra devem receber **tratamento probabilístico**.
- ▶ Levando isso em conta, são objetivos da inferência estatística:
 1. Estimar quantidades com base apenas na amostra (**estimativa pontual**).
 2. Avaliar o quão preciso ou creditável é o valor estimado (**intervalo de confiança**).
 3. Decidir sobre possíveis valores da quantidade baseado apenas na amostra (**teste de hipótese**).



Alguns conceitos importantes

Alguns conceitos importantes

- ▶ **Parâmetro:** uma medida numérica que descreve alguma característica da população.
 - ▶ Na maior parte dos casos são desconhecidos.
 - ▶ Usualmente representados por letras gregas (θ , μ , σ , etc).
- ▶ **Espaço paramétrico:** conjunto de valores que um parâmetro pode assumir.
- ▶ **Estimador:** função da variável aleatória.
 - ▶ Cálculo efetuado com os elementos da amostra com a finalidade de representar (estimar) um parâmetro na população.
 - ▶ Usualmente representados por letras gregas com acento circunflexo ($\hat{\theta}$, $\hat{\mu}$, $\hat{\sigma}$, etc).

Alguns conceitos importantes

► **Estimativa/estatística:**

- Valores numéricos assumidos pelos estimadores.
- Realização de um estimador.
- Uma função dos valores observados.
- Função que define o estimador avaliada em dados observados.
- Um número.

► **Estimativa pontual:** um único valor numérico como candidato para o parâmetro de interesse.

► **Estimativa intervalar:** intervalo conjunto de valores “plausíveis” para o parâmetro de interesse.

Um exemplo prático

- ▶ Suponha que temos interesse em estimar a **idade média** de alunos de um curso de graduação.
- ▶ Calcular a **média populacional** é muito custoso, por isso, tomou-se uma **amostra** da população.
- ▶ Com essa amostra foi usado um **estimador** para chegar a uma **estimativa** da média populacional baseada na amostra.
- ▶ Complementar à estimativa pontual foi construído um **intervalo de confiança** para esta estimativa.
- ▶ A coordenação do curso tem interesse em avaliar se existe evidência suficiente nos dados que permite afirmar que a idade média é menor que 22 anos. Tarefa que pode ser cumprida por meio de um **teste de hipóteses**.

Diferentes paradigmas

- ▶ Existem diferentes paradigmas de Inferência Estatística, baseados em formas diferentes de sistematizar os problemas.
- ▶ Outros paradigmas são o *Bayesiano* e *Verossimilhança*.
- ▶ Os problemas de Inferência também podem ser abordados por meio de técnicas computacionalmente intensivas, como *Bootstrap*.
- ▶ Nesta disciplina nosso foco será o **paradigma frequentista**, que tem a **distribuição amostral** como objeto central.



Distribuição amostral

Distribuição amostral

- ▶ Suponha que estamos interessados em uma variável aleatória na população, denotada por Y (por exemplo, o peso dos indivíduos).
- ▶ Desta variável aleatória tomamos uma amostra de tamanho n , que denotaremos por $Y_1, Y_2, \dots, Y_n$ (por exemplo, uma amostra de pesos dos indivíduos da população).
- ▶ Em geral, consideramos que esta amostra é aleatória simples com reposição para garantir que os elementos da amostra sejam independentes e identicamente distribuídos (iid).

Distribuição amostral

- ▶ Suponha que temos interesse em uma quantidade populacional θ (por exemplo, o peso médio dos indivíduos).
- ▶ Para obter o real valor de θ precisaríamos avaliar toda a população, na maior parte das vezes isso é inviável.
- ▶ A solução é estimar θ por meio de um estimador $\hat{\theta}$ que é uma função das variáveis aleatórias constituintes da amostra, isto é, $\hat{\theta} = f(Y_1, Y_2, \dots, Y_n)$.

Distribuição amostral


- ▶ Estimativas variam de forma **aleatória** (sabemos o que pode acontecer, mas não o que vai acontecer) de amostra para amostra.
- ▶ O estimador é portanto uma **variável aleatória** que tem uma distribuição de probabilidade.
- ▶ A **distribuição de probabilidades do estimador** é chamada de **distribuição amostral**.
- ▶ Para estudar um **parâmetro**, usamos a distribuição amostral.
- ▶ No **paradigma frequentista** pensamos no que aconteceria se diversas amostras fossem tomadas e em cada amostra a quantidade de interesse fosse obtida.

Distribuição amostral

- ▶ Imagine que:
 - ▶ Coletamos diversas amostras.
 - ▶ Em cada amostra calculamos o estimador de interesse (uma média, por exemplo).
 - ▶ Se obtivermos a distribuição empírica deste estimador, temos tudo que precisamos para fazer inferência.
- ▶ A distribuição amostral pode ser usada para avaliar o que aconteceria se o estudo fosse replicado um grande número de vezes.
- ▶ A distribuição amostral é o objeto de inferência (frequentista).

Distribuição amostral

- ▶ A **estimativa pontual** é um resumo da distribuição amostral.
- ▶ Intervalos entre **quantis** representam a incerteza sobre o valor estimado.
- ▶ Contudo, na prática temos apenas **uma** amostra.
- ▶ Mas diversas estatísticas de interesse tem distribuições amostrais conhecidas, como média, variância e proporção.
- ▶ Usamos estas distribuições baseadas no valor obtido da amostra.



Principais estimadores e estimativas

Principais estimadores e estimativas

- ▶ Denote os parâmetros média, variância e proporção de certa característica na população por μ , σ^2 e p , respectivamente.
- ▶ Os estimadores “naturais” para estas quantidades são as correspondentes média, variância e proporção calculadas na amostra.

$$\hat{\mu} = \bar{Y} = \frac{\sum_{i=1}^n Y_i}{n}$$

$$\hat{p} = \frac{\text{número de sucessos}}{n}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

Distribuição amostral da média: V.a. Normal

- ▶ Seja $Y_i \sim N(\mu, \sigma^2)$ para $i = 1, \dots, N$. Suponha que uma amostra aleatória de tamanho n , com valores observados denotados por $y_1, \dots, y_n$ foi obtida. A distribuição amostral da média $\bar{Y}$ é dada por

$$\bar{Y} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

- ▶ Segue do fato de que **combinação linear** de Normal é Normal e de que

$$E(\bar{Y}) = \frac{1}{n} \sum_{i=1}^n E(Y_i) = \frac{n\mu}{n} = \mu.$$

$$V(\bar{Y}) = \frac{1}{n^2} \sum_{i=1}^n V(Y_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

Exemplo: Salário de pilotos

O salário anual médio dos pilotos de avião pode ser modelado por uma distribuição Normal com média de R\$41979,00 e desvio padrão de R\$5000,00. Suponha que uma amostra aleatória simples de 50 pilotos seja selecionada.

- ▶ Qual é o desvio padrão da média amostral?
- ▶ Qual é a probabilidade da média amostral ser maior que R\$41979,00?
- ▶ Qual é a probabilidade da média amostral não diferir da média populacional em até R\$1000,00?
- ▶ Como a probabilidade do item anterior seria alterada caso a amostra fosse de tamanho 100?

Exemplo: Salário de pilotos (cont.)

- ▶ Qual é o desvio padrão da média amostral?

$V(\bar{Y}) = \frac{\sigma^2}{n}$. Assim, a variância é $\frac{5000^2}{50}$ e o desvio padrão da média $\frac{5000}{\sqrt{50}}$.

- ▶ Qual é a probabilidade da média amostral ser maior que R\$41979,00?

$$P(\bar{Y} > 41979) = P\left(Z > \frac{41979 - 41979}{5000/\sqrt{50}}\right) = P(Z > 0) = 0,5.$$

- ▶ Qual é a probabilidade da média amostral não diferir da média populacional em até R\$1000,00?

$$\begin{aligned} P(40979 < \bar{Y} < 42979) &= P\left(\frac{40979 - 41979}{5000/\sqrt{50}} < Z < \frac{42979 - 41979}{5000/\sqrt{50}}\right) \\ &= P(-1.414 < Z < 1.414) \approx 0,842. \end{aligned}$$

Exemplo: Salário de pilotos (cont.)

- Como a probabilidade do item anterior seria alterada caso a amostra fosse de tamanho 100?

$$\begin{aligned} P(40979 < \bar{Y} < 42979) &= P\left(\frac{40979 - 41979}{5000/\sqrt{100}} < Z < \frac{42979 - 41979}{5000/\sqrt{100}}\right) \\ &= P(-2 < Z < 2) \approx 0,954. \end{aligned}$$

Exemplo: Acesso à internet

Uma pesquisa divulgou que 56% das famílias brasileiras têm acesso à internet. Suponha que esta seja a verdadeira proporção populacional $p = 0,56$ e suponha que uma amostra de 300 famílias seja selecionada.

- ▶ Apresente a distribuição amostral de $\hat{p}$, em que $\hat{p}$ é a proporção amostral de famílias com acesso à internet.
- ▶ Qual a probabilidade de a proporção amostral não diferir da populacional em mais de 0,03?
- ▶ Responda o item anterior considerando amostras de tamanho 600 e 1000.


Exemplo: Acesso à internet (comentários)

- ▶ Note que agora temos que a distribuição da v.a. **não** é Normal.
- ▶ Y - acesso à internet (SIM ou NÃO).
- ▶ $Y \sim \text{Ber}(p)$ com p sendo a probabilidade de ter acesso à internet.
- ▶ Sabemos que $E(Y) = p$ e $V(Y) = p(1 - p)$.
- ▶ Sendo $\hat{p} = \frac{1}{n} \sum_{i=1}^n Y_i$, podemos facilmente obter

$$E(\hat{p}) = \frac{1}{n} \sum_{i=1}^n E(Y_i) = \frac{np}{n} = p.$$

$$V(\hat{p}) = \frac{1}{n^2} \sum_{i=1}^n V(Y_i) = \frac{np(1 - p)}{n^2} = \frac{p(1 - p)}{n}.$$

- ▶ Conseguimos obter a média e a variância de $\hat{p}$, mas e a distribuição?



Teorema Central do Limite

Teorema Central do Limite

- ▶ A média é uma das quantidades de maior interesse em contextos práticos.
- ▶ A distribuição amostral da média é conhecida graças ao Teorema Central do Limite (TCL).
- ▶ Segundo o teorema, quanto maior o tamanho da amostra, a distribuição da média amostral se comporta segundo um modelo Normal.

Teorema Central do Limite

- ▶ Suponha uma amostra aleatória de tamanho n retirada de uma população com média μ e variância σ^2 finita.
- ▶ Note que o modelo da variável aleatória não é especificado.
- ▶ A amostra $(Y_1, Y_2, \dots, Y_n)$ consiste de n variáveis aleatórias independentes e identicamente distribuídas.

Teorema Central do Limite

Segundo o teorema:

$$\left(\frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \right) \xrightarrow{D} Z \sim N(0,1), \text{ para } n \rightarrow \infty$$

De forma alternativa:

$$\bar{Y} \sim N(\mu; \sigma^2/n)$$

O resultado pode ser generalizado para proporções:

$$\hat{p} \sim N \left(p; \frac{p(1-p)}{n} \right)$$

Distribuições amostrais

Média e variância

- ▶ Se σ^2 é conhecido
 - ▶ $\hat{\mu} \sim N(\mu; \sigma^2/n)$.
 - ▶ $(\hat{\mu} - \mu)/(\sigma/\sqrt{n}) \sim N(0; 1)$.
- ▶ Se σ^2 é desconhecido
 - ▶ $(\hat{\mu} - \mu)/(S/\sqrt{n}) \sim t_{n-1}$.
 - ▶ $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$.

Proporção

- ▶ $\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$.

Exemplo: Acesso à internet (cont.)

- ▶ Apresente a distribuição amostral de $\hat{p}$, em que $\hat{p}$ é a proporção amostral de famílias com acesso à internet.
- ▶ Usando o TLC, temos

$$\hat{p} \sim N \left(p, \frac{p(1-p)}{n} \right).$$

- ▶ Qual a probabilidade de a proporção amostral não diferir da populacional em mais de 0,03?

$$P(0,53 < \hat{p} < 0,59) = P(-1,046 < Z < 1,046) \approx 0,704.$$

$$P \left(\frac{0,53 - 0,56}{\sqrt{0,56(1 - 0,56)/300}} < \frac{\hat{p} - p}{\sqrt{p(1-p)/n}} < \frac{0,59 - 0,56}{\sqrt{0,56(1 - 0,56)/300}} \right).$$

Exemplo: Acesso à internet (cont.)

- ▶ Responda o item anterior considerando amostras de tamanho 600 e 1000.
- ▶ $n = 600 \rightarrow P(0,53 < \hat{p} < 0,59) = P(-1,480 < Z < 1,480) \approx 0,861$.

$$P\left(\frac{0,53 - 0,56}{\sqrt{0,56(1 - 0,56)/600}} < \frac{\hat{p} - p}{\sqrt{p(1 - p)/n}} < \frac{0,59 - 0,56}{\sqrt{0,56(1 - 0,56)/600}}\right).$$

- ▶ $n = 1000 \rightarrow P(0,53 < \hat{p} < 0,59) = P(-1,911 < Z < 1,911) \approx 0,944$.

$$P\left(\frac{0,53 - 0,56}{\sqrt{0,56(1 - 0,56)/1000}} < \frac{\hat{p} - p}{\sqrt{p(1 - p)/n}} < \frac{0,59 - 0,56}{\sqrt{0,56(1 - 0,56)/1000}}\right).$$



Ilustração computacional

Ilustração computacional

- ▶ Um questionário foi aplicado a alunos de uma turma de Estatística com diversas questões sobre características dos alunos.
- ▶ Uma das questões perguntava o peso dos alunos. Consideraremos que a turma é uma população e temos interesse em fazer inferência sobre o peso médio desta população.
- ▶ Para isso:
 1. Tomamos diversas amostras.
 2. Para cada amostra calculamos o peso médio.
 3. Considerando o vetor de médias, construímos a distribuição amostral.
 4. Com base na distribuição amostral empírica, fazemos inferência (estimativa pontual e intervalar).
- ▶ Neste caso, sabemos o verdadeiro peso médio. Logo, podemos verificar se nossa inferência foi bem sucedida.

Ilustração computacional




Ilustração computacional





Ilustração computacional

- ▶ Os resultados mostram que não precisamos olhar a população para ter uma estimativa satisfatoriamente próxima do verdadeiro valor do parâmetro de interesse.
- ▶ Contudo esta estratégia é inviável na prática, pois necessita de várias amostras.
- ▶ Verificamos que a distribuição amostral é simétrica.
- ▶ O teorema central do limite garante que esta distribuição é Normal.

Ilustração computacional

Comparação distribuição amostral baseada no TLC x distribuição amostral construída



O que foi visto:

- ▶ Introdução à Inferência estatística.
- ▶ Conceitos importantes.
- ▶ Distribuição amostral.
- ▶ Distribuição amostral da média.
- ▶ Ilustração computacional.

Próximos assuntos:

- ▶ Estimação pontual e intervalar.
 - ▶ Média com variância conhecida.
 - ▶ Média com variância desconhecida.
 - ▶ Proporção.